

# 人机交互技术： BCI中的机器学习--线性模型

- 线性回归
  - ❖ 最小二乘法
- 二分类任务
  - ❖ 对数几率回归
  - ❖ 线性判别分析
- 多分类任务
  - ❖ 一对一
  - ❖ 一对其余
- 类别不平衡问题

# 基本形式

- 线性模型一般形式:

$$f(\mathbf{x}) = w_1x_1 + w_2x_2 + \dots + w_dx_d + b$$

$\mathbf{x} = (x_1; x_2; \dots; x_d)$  是由属性描述的示例, 其中  $x_i$  是  $\mathbf{x}$  在第  $i$  个属性上的取值.

- 向量形式:

$$f(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b$$

其中

$$\mathbf{w} = (w_1; w_2; \dots; w_d)$$

# 线性模型优点

- 形式简单、易于建模
- 可解释性
- 非线性模型的基础
  - ❖ 引入层级结构或高维映射
- 一个例子:

- ❖ 综合考虑色泽、根蒂和敲声来判断西瓜好不好

$$f_{\text{好瓜}}(\boldsymbol{x}) = 0.2 \cdot x_{\text{色泽}} + 0.5 \cdot x_{\text{根蒂}} + 0.3 \cdot x_{\text{敲声}} + 1$$

- ❖ 其中根蒂的系数最大，表明根蒂最要紧；而敲声的系数比色泽大，说明敲声比色泽更重要

# 线性回归

- 给定数据集  $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$

其中  $\mathbf{x}_i = (x_{i1}; x_{i2}; \dots; x_{id})$  ,  $y_i \in \mathbb{R}$

- 线性回归（linear regression）目的：
  - ❖ 学得一个线性模型以尽可能准确地预测实值输出标记
- 离散属性处理
  - ❖ 有“序”关系
    - 连续化为连续值
  - ❖ 无“序”关系
    - 有 $k$ 个属性值，则转换为 $k$ 维向量

# 线性回归

- 单一属性的线性回归目标:

$$f(x) = wx_i + b \quad \text{使得} \quad f(x_i) \simeq y_i$$

- 参数/模型估计: 最小二乘法 (least square method)

$$\begin{aligned} (w^*, b^*) &= \arg \min_{(w, b)} \sum_{i=1}^m (f(x_i) - y_i)^2 \\ &= \arg \min_{(w, b)} \sum_{i=1}^m (y_i - wx_i - b)^2 \end{aligned}$$

# 线性回归 - 最小二乘法

最小化均方误差:  $E_{(w,b)} = \sum_{i=1}^m (y_i - wx_i - b)^2$

分别对  $w$  和  $b$  求导, 可得:

$$\frac{\partial E_{(w,b)}}{\partial w} = 2 \left( w \sum_{i=1}^m x_i^2 - \sum_{i=1}^m (y_i - b) x_i \right)$$

$$\frac{\partial E_{(w,b)}}{\partial b} = 2 \left( mb - \sum_{i=1}^m (y_i - wx_i) \right)$$

得到闭式 (closed-form) 解:

$$w = \frac{\sum_{i=1}^m y_i (x_i - \bar{x})}{\sum_{i=1}^m x_i^2 - \frac{1}{m} \left( \sum_{i=1}^m x_i \right)^2}$$

$$b = \frac{1}{m} \sum_{i=1}^m (y_i - wx_i)$$

$$\bar{x} = \frac{1}{m} \sum_{i=1}^m x_i$$

# 多元线性回归

- 给定数据集

$$D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$$

$$\mathbf{x}_i = (x_{i1}; x_{i2}; \dots; x_{id}) \quad y_i \in \mathbb{R}$$

- 多元线性回归目标:

$$f(\mathbf{x}_i) = \mathbf{w}^T \mathbf{x}_i + b \quad \text{使得} \quad f(\mathbf{x}_i) \simeq y_i$$

# 多元线性回归

把  $w$  和  $b$  吸收入向量形式  $\hat{w} = (w; b)$ , 数据集表示为:

$$\mathbf{X} = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1d} & 1 \\ x_{21} & x_{22} & \cdots & x_{2d} & 1 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ x_{m1} & x_{m2} & \cdots & x_{md} & 1 \end{pmatrix} = \begin{pmatrix} \mathbf{x}_1^T & 1 \\ \mathbf{x}_2^T & 1 \\ \vdots & \vdots \\ \mathbf{x}_m^T & 1 \end{pmatrix}$$

$$\mathbf{y} = (y_1; y_2; \cdots; y_m)$$



# 多元线性回归 - 最小二乘法

最小二乘法（least square method）：

$$\hat{\boldsymbol{w}}^* = \arg \min_{\hat{\boldsymbol{w}}} (\boldsymbol{y} - \boldsymbol{X}\hat{\boldsymbol{w}}^T) (\boldsymbol{y} - \boldsymbol{X}\hat{\boldsymbol{w}})$$

令  $E_{\hat{\boldsymbol{w}}} = (\boldsymbol{y} - \boldsymbol{X}\hat{\boldsymbol{w}})^T (\boldsymbol{y} - \boldsymbol{X}\hat{\boldsymbol{w}})$  ，对  $\hat{\boldsymbol{w}}$  求导得到：

$$\frac{\partial E_{\hat{\boldsymbol{w}}}}{\partial \hat{\boldsymbol{w}}} = 2\boldsymbol{X}^T (\boldsymbol{X}\hat{\boldsymbol{w}} - \boldsymbol{y})$$

令上式为零可得  $\hat{\boldsymbol{w}}$  最优解的闭式解

# 多元线性回归 - 满秩讨论

- $\mathbf{X}^T \mathbf{X}$  是满秩矩阵, 则

$$\hat{\mathbf{w}}^* = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

其中  $(\mathbf{X}^T \mathbf{X})^{-1}$  是  $\mathbf{X}^T \mathbf{X}$  的逆矩阵, 线性回归模型为

$$f(\hat{\mathbf{x}}_i) = \hat{\mathbf{x}}_i^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

- $\mathbf{X}^T \mathbf{X}$  不是满秩矩阵
  - ❖ 根据归纳偏好选择解
  - ❖ 引入正则化

# 正则化：岭回归与LASSO


- 岭回归  $\hat{\beta}(k) = (X'X + kI)^{-1}X'y$  可以看做对下式的解析求解

$$\hat{\beta}(k) = \operatorname{argmin}_{\beta} \{ (y - X\beta)^T (y - X\beta) + k\|\beta\|^2 \}$$

- 其中  $\|\beta\|^2$  称作正则化项
  - 使得模型参数有向0收缩的趋势
  - 通过部分参数向0收缩来缓解过拟合的问题
- 模型优化中常采用参数  $p$  阶范式  $\|W\|^p$  做正则约束来防止过拟合
  - $p = 1$  时称作 LASSO ( The Least Absolute Shrinkage and Selectionator operator ) , 倾向于稀疏参数或特征选择

# 对数线性回归

线性模型逼近的目标: 输出标记的对数




$$\ln y = w^T x + b$$



$$y = w^T x + b$$

# 大纲

- 线性回归
    - ❖ 最小二乘法
  - 二分类任务
    - ❖ 对数几率回归
    - ❖ 线性判别分析
  - 多分类任务
    - ❖ 一对一
    - ❖ 一对其余
  - 类别不平衡问题
- 

# 二分类任务

- 预测值与输出标记

$$z = \mathbf{w}^T \mathbf{x} + b \quad y \in \{0, 1\}$$

- 寻找函数将分类标记与线性回归模型输出联系起来

$$y = \begin{cases} 0, & z < 0; \\ 0.5, & z = 0; \\ 1, & z > 0, \end{cases}$$

- 最理想的函数: 单位阶跃函数


# 二分类任务

- 单位阶跃函数缺点: 不连续
- 替代函数——对数几率函数 (logistic function)

❖ 单调可微、任意阶可导

$$y = \frac{1}{1 + e^{-z}}$$

单位阶跃函数与对数几率函数的比较



# 对数几率回归

- 运用对数几率函数

$$y = \frac{1}{1 + e^{-z}} \quad \text{变为} \quad y = \frac{1}{1 + e^{-(\mathbf{w}^T \mathbf{x} + b)}}$$

- 对数几率（log odds）


❖ 样本作为正例的相对可能性的对数:  $\ln \frac{y}{1 - y}$

- 对数几率回归优点

- ❖ 无需事先假设数据分布
- ❖ 可得到“类别”的近似概率预测
- ❖ 可直接应用现有数值优化算法求取最优解




# 大纲

- 线性回归
    - ❖ 最小二乘法
  - 二分类任务
    - ❖ 对数几率回归
    - ❖ 线性判别分析
  - 多分类任务
    - ❖ 一对一
    - ❖ 一对其余
  - 类别不平衡问题
- 

# 二分类任务- 线性判别分析

线性判别分析 (Linear Discriminant Analysis)



LDA也可被视为一种监督降维技术

# 二分类任务- 线性判别分析

- LDA的思想:
  - ❖ 欲使同类样例的投影点尽可能接近, 可以让同类样例投影点的协方差尽可能小
  - ❖ 欲使异类样例的投影点尽可能远离, 可以让类中心之间的距离尽可能大
- 一些变量:
  - ❖ 第  $i$  类示例的集合  $X_i$
  - ❖ 第  $i$  类示例的均值向量  $\mu_i$
  - ❖ 第  $i$  类示例的协方差矩阵  $\Sigma_i$
  - ❖ 两类样本的中心在直线上的投影:  $\mathbf{w}^T \mu_0$  和  $\mathbf{w}^T \mu_1$
  - ❖ 两类样本的协方差:  $\mathbf{w}^T \Sigma_0 \mathbf{w}$  和  $\mathbf{w}^T \Sigma_1 \mathbf{w}$

# 二分类任务- 线性判别分析

- 最大化目标

$$\begin{aligned} J &= \frac{\|w^T \mu_0 - w^T \mu_1\|_2^2}{w^T \Sigma_0 w + w^T \Sigma_1 w} \\ &= \frac{w^T (\mu_0 - \mu_1) (\mu_0 - \mu_1)^T w}{w^T (\Sigma_0 + \Sigma_1) w} \end{aligned}$$

- 类内散度矩阵

$$\begin{aligned} S_w &= \Sigma_0 + \Sigma_1 \\ &= \sum_{x \in X_0} (x - \mu_0) (x - \mu_0)^T + \sum_{x \in X_1} (x - \mu_1) (x - \mu_1)^T \end{aligned}$$

- 类间散度矩阵  $S_b = (\mu_0 - \mu_1) (\mu_0 - \mu_1)^T$

# 二分类任务- 线性判别分析

- 广义瑞利商 (generalized Rayleigh quotient)

$$J = \frac{\mathbf{w}^T \mathbf{S}_b \mathbf{w}}{\mathbf{w}^T \mathbf{S}_w \mathbf{w}}$$

- 令  $\mathbf{w}^T \mathbf{S}_w \mathbf{w} = 1$ , 最大化广义瑞利商等价形式为

$$\begin{aligned} \min_{\mathbf{w}} \quad & -\mathbf{w}^T \mathbf{S}_b \mathbf{w} \\ \text{s.t.} \quad & \mathbf{w}^T \mathbf{S}_w \mathbf{w} = 1 \end{aligned}$$

- 运用拉格朗日乘子法  $\mathbf{S}_b \mathbf{w} = \lambda \mathbf{S}_w \mathbf{w}$

# 二分类任务- 线性判别分析

- 同向向量

$$S_b w = \lambda (\mu_0 - \mu_1)$$

同向向量

- 结果  $w = S_w^{-1} (\mu_0 - \mu_1)$


- 求解

- ❖ 奇异值分解  $S_w = U \Sigma V^T$

- LDA的贝叶斯决策论解释

- ❖ 两类数据同先验、满足高斯分布且协方差相等时，LDA达到最优分类

# 大纲

- 线性回归
    - ❖ 最小二乘法
  - 二分类任务
    - ❖ 对数几率回归
    - ❖ 线性判别分析
  - 多分类任务
    - ❖ 一对一
    - ❖ 一对其余
  - 类别不平衡问题
- 

# 多分类学习

- 二分类学习方法推广到多类
- 利用二分类学习器解决多分类问题（常用）
  - ❖ 对问题进行拆分，为拆出的每个二分类任务训练一个分类器
  - ❖ 对于每个分类器的预测结果进行集成以获得最终的多分类结果
- 拆分策略
  - ❖ 一对一（One vs. One, OvO）
  - ❖ 一对其余（One vs. Rest, OvR）
  - ❖ 多对多（Many vs. Many, MvM）



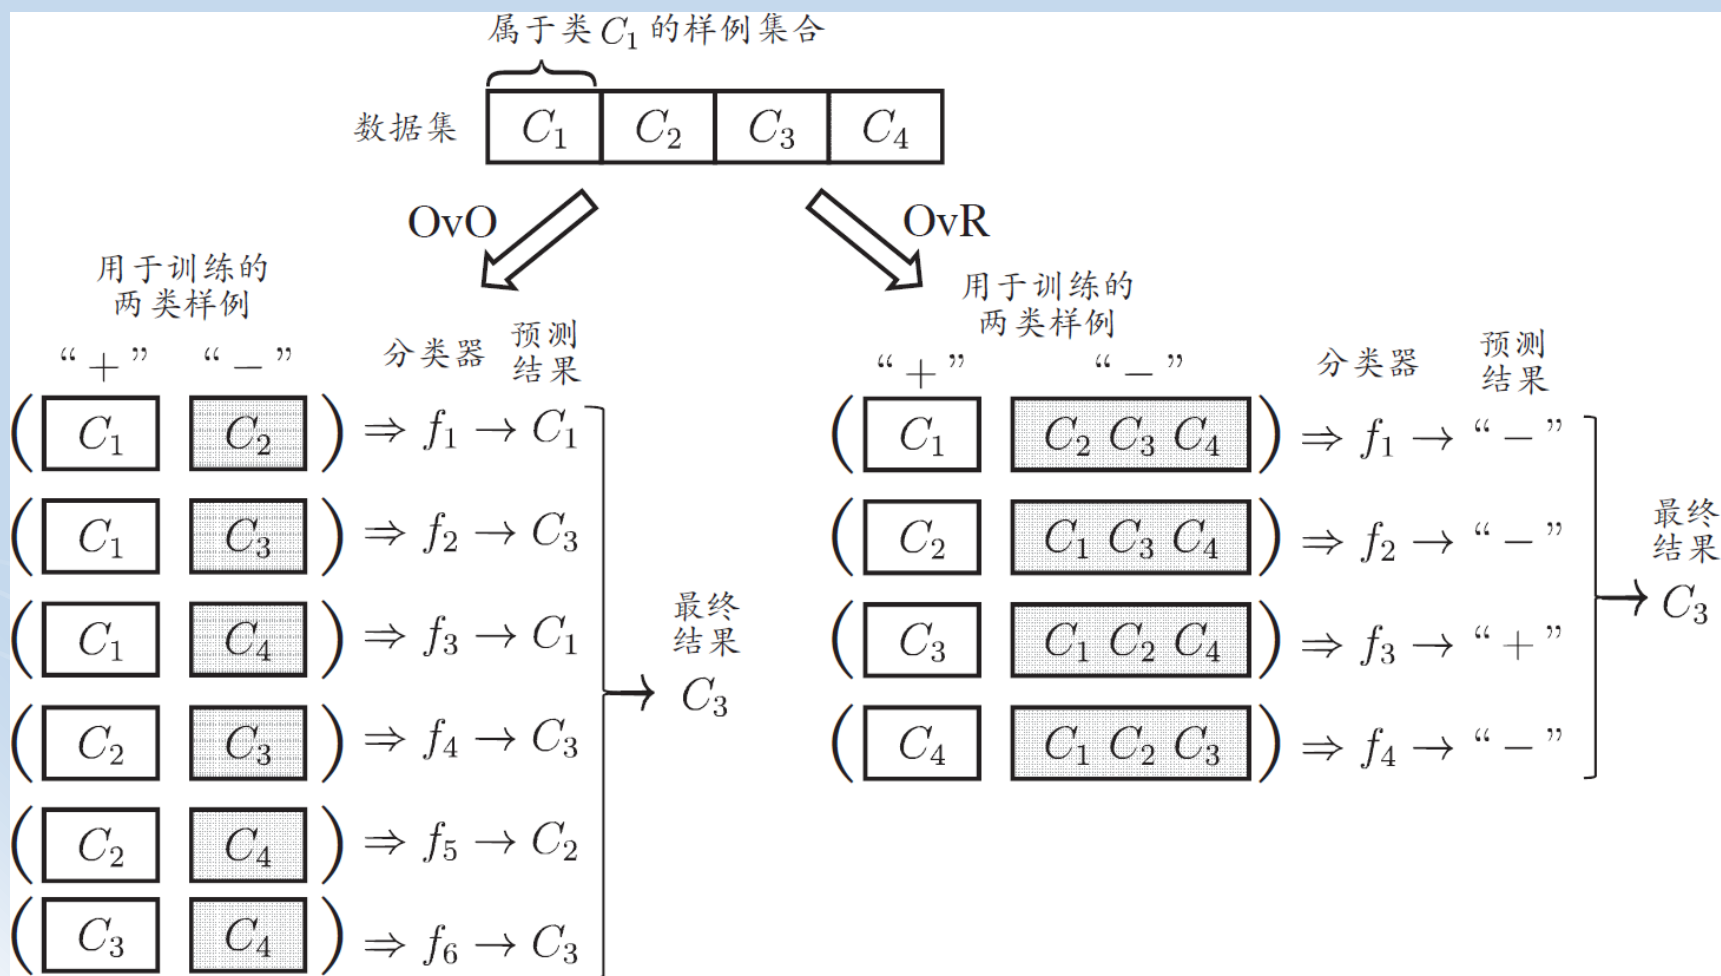
# 多分类学习- 一对一

- 拆分阶段
  - ❖  $N$ 个类别两两配对:  $N(N-1)/2$  个二类任务
  - ❖ 各个二类任务学习分类器:  $N(N-1)/2$  个二类分类器
- 测试阶段
  - ❖ 新样本提交给所有分类器预测
    - $N(N-1)/2$  个分类结果
  - ❖ 投票产生最终分类结果
    - 被预测最多的类别为最终类别

# 多分类学习- 一对其余

- 任务拆分
  - ❖ 某一类作为正例，其他反例:  $N$  个二类任务
  - ❖ 各个二类任务学习分类器:  $N$  个二类分类器
- 测试阶段
  - ❖ 新样本提交给所有分类器预测
    - $N$  个分类结果
  - ❖ 比较各分类器预测置信度
    - 置信度最大类别作为最终类别

# 多分类学习- 两种策略比较



# 多分类学习– 两种策略比较

## 一对一：

- 训练 $N(N-1)/2$ 个分类器，存储开销和测试时间大
- 训练只用两个类的样例，训练时间短

## 一对其余：

- 训练 $N$ 个分类器，存储开销和测试时间小
- 训练用到全部训练样例，训练时间长

预测性能取决于具体数据分布，多数情况下两者差不多

# 多分类学习- 多对多

- 多对多 (Many vs Many, MvM)

- ❖ 若干类作为正类, 若干类作为反类

- 纠错输出码 (Error Correcting Output Code, ECOC)

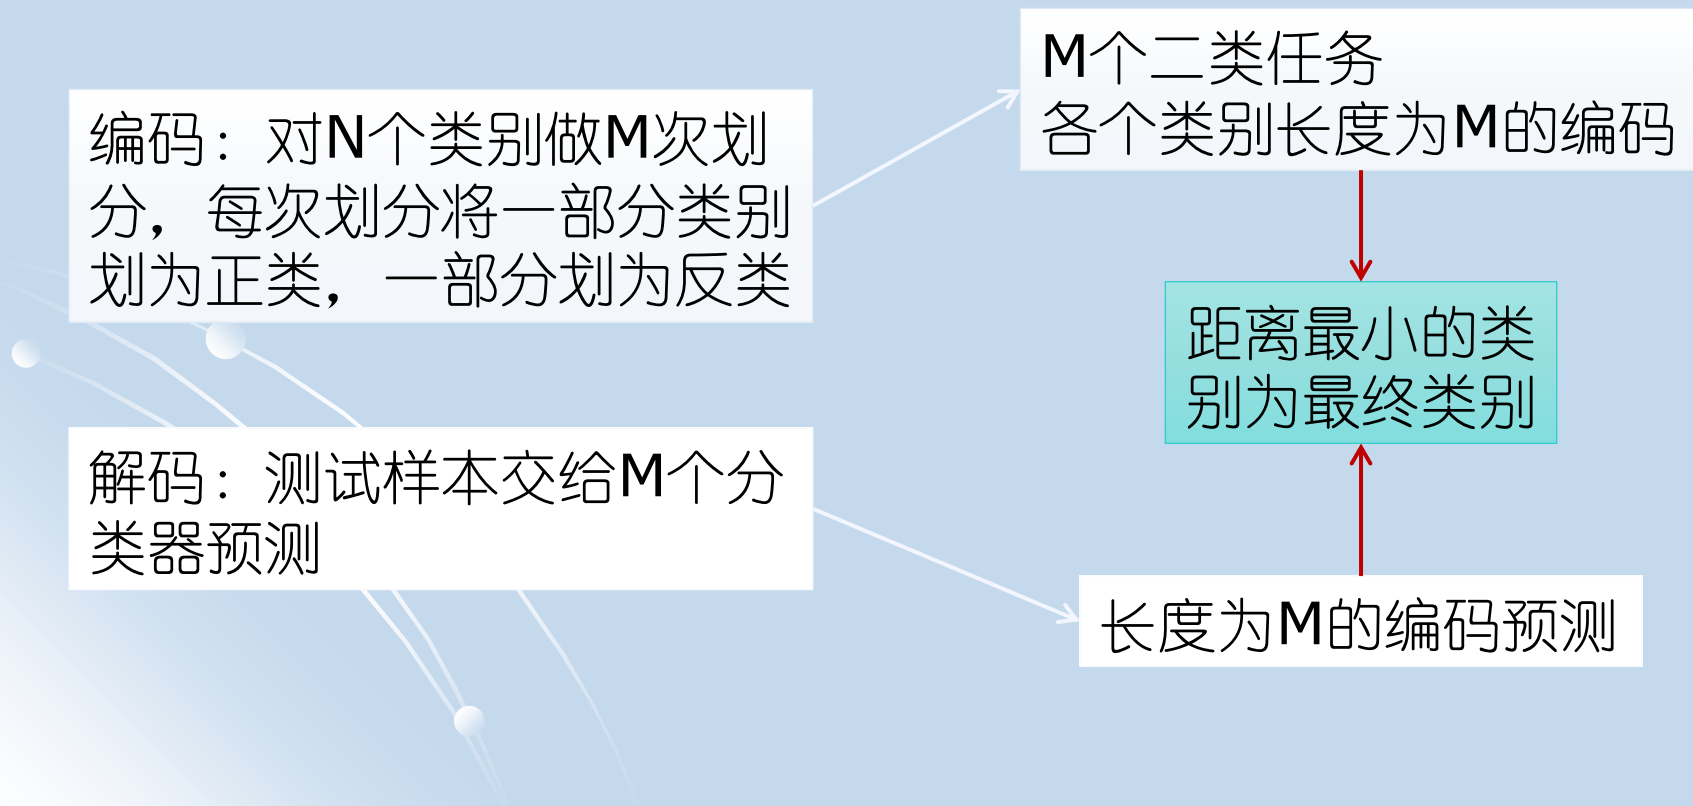
编码: 对 $N$ 个类别做 $M$ 次划分, 每次划分将一部分类别划为正类, 一部分划为反类

$M$ 个二类任务  
各个类别长度为 $M$ 的编码

距离最小的类别为最终类别

解码: 测试样本交给 $M$ 个分类器预测

长度为 $M$ 的编码预测



# 多分类学习- 多对多

- 纠错输出码(Error Correcting Output Code, ECOC)

	$f_1$	$f_2$	$f_3$	$f_4$	$f_5$	海明 距离	欧氏 距离		$f_1$	$f_2$	$f_3$	$f_4$	$f_5$	$f_6$	$f_7$	海明 距离	欧氏 距离
	↓	↓	↓	↓	↓	↓	↓		↓	↓	↓	↓	↓	↓	↓	↓	↓
$C_1 \rightarrow$	-1	+1	-1	+1	+1	→ 3	$2\sqrt{3}$	$C_1 \rightarrow$	-1	-1	+1	+1	-1	+1	+1	→ 4	4
$C_2 \rightarrow$	+1	-1	-1	+1	-1	→ 4	4	$C_2 \rightarrow$	-1	0	0	0	+1	-1	0	→ 2	2
$C_3 \rightarrow$	-1	+1	+1	-1	+1	→ 1	2	$C_3 \rightarrow$	+1	+1	-1	-1	-1	+1	-1	→ 5	$2\sqrt{5}$
$C_4 \rightarrow$	-1	-1	+1	+1	-1	→ 2	$2\sqrt{2}$	$C_4 \rightarrow$	-1	+1	0	+1	-1	0	+1	→ 3	$\sqrt{10}$
测试 示例	-1	-1	+1	-1	+1	↑	↑	测试 示例	-1	+1	+1	-1	+1	-1	+1	↑	↑

(a) 二元 ECOC 码

(b) 三元 ECOC 码

[Dietterich and Bakiri,1995]

[Allwein et al. 2000]

- ECOC编码对分类器错误有一定容忍和修正能力，编码越长、纠错能力越强
- 对同等长度的编码，理论上来说，任意两个类别之间的编码距离越远，则纠错能力越强

# 类别不平衡问题

- 类别不平衡 (class imbalance)

- ❖ 不同类别训练样例数相差很大情况 (正类为小类)

类别平衡正例预测  $\frac{y}{1-y} > 1$    $\frac{y}{1-y} > \frac{m^+}{m^-}$  正负类比例

- 再缩放

- ❖ 欠采样 (undersampling)

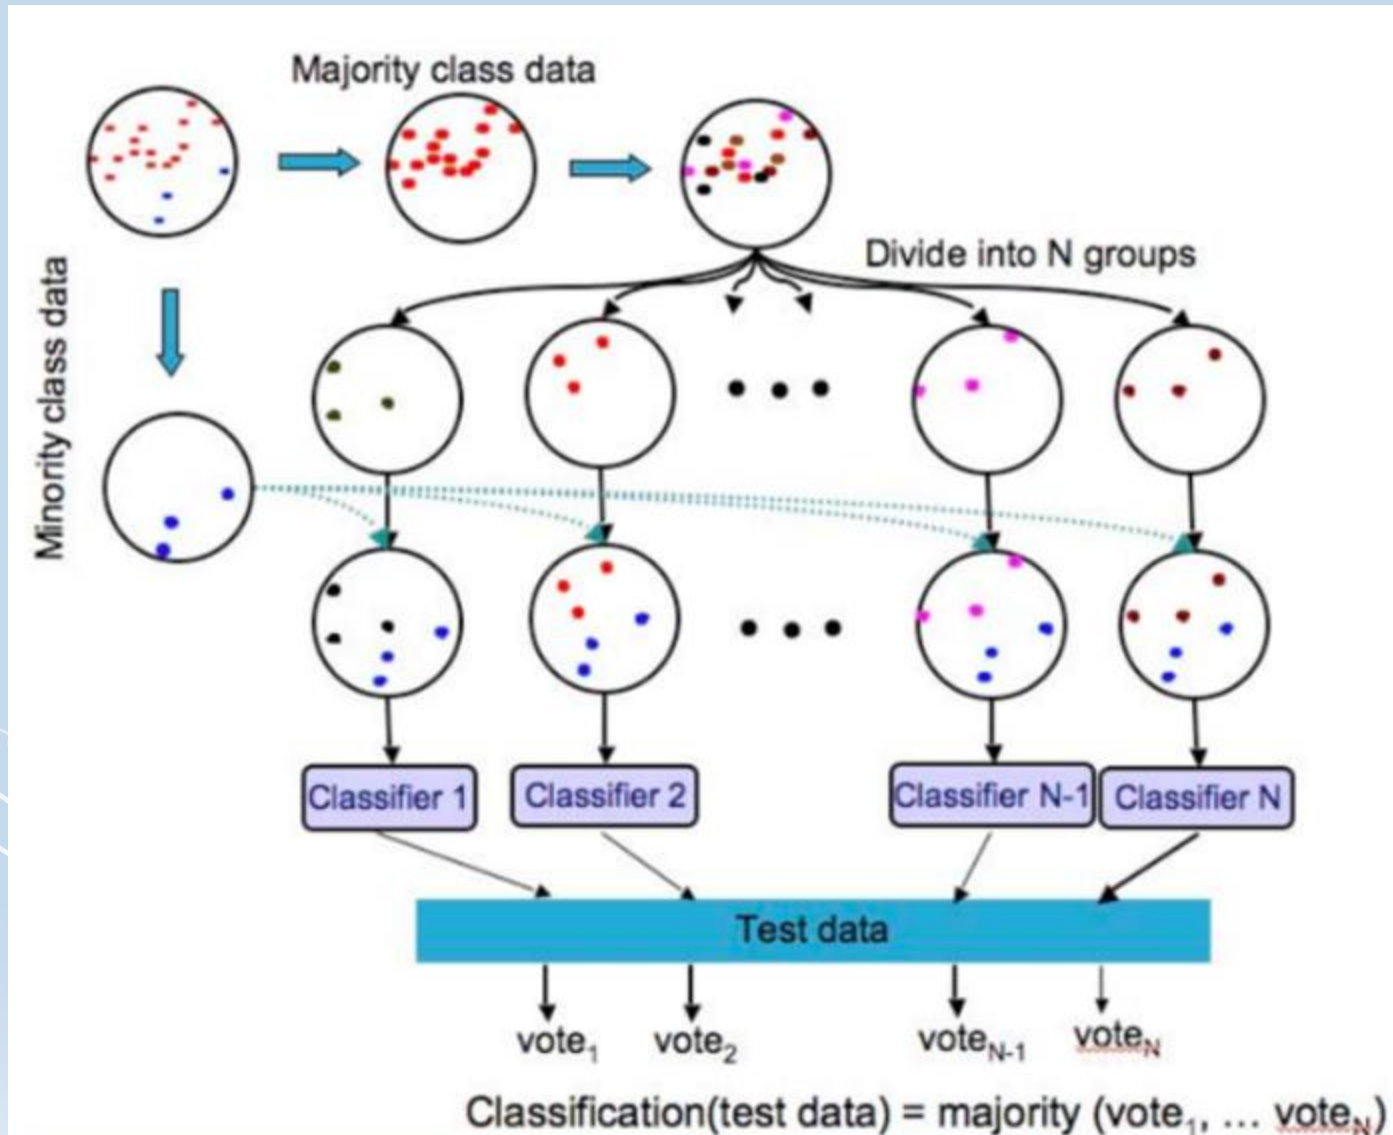
- 去除一些反例使正反例数目接近 (EasyEnsemble)

- ❖ 过采样 (oversampling)

- 增加一些正例使正反例数目接近 (SMOTE)


- ❖ 阈值移动 (threshold-moving)

# EasyEnsemble







# SMOTE




1. For each minority example  $k$  compute nearest minority class examples  $(i, j, l, n, m)$



2. Randomly choose an example out of 5 closest points



3. Synthetically generate event  $k_1$ , such that  $k_1$  lies between  $k$  and  $i$



4. Dataset after applying SMOTE 3 times

# 优化提要

- 各任务下（回归、分类）各个模型优化的目标
  - ❖ 最小二乘法：最小化均方误差
  - ❖ 对数几率回归：最大化样本分布似然
  - ❖ 线性判别分析：投影空间内最小（大）化类内（间）散度
- 参数的优化方法
  - ❖ 最小二乘法：线性代数
  - ❖ 对数几率回归：凸优化梯度下降、牛顿法
  - ❖ 线性判别分析：矩阵论、广义瑞利商

# 总结

- 线性回归: 最小二乘法（最小化均方误差）
- 二分类任务
  - ❖ 对数几率回归
    - 单位阶跃函数、对数几率函数、极大似然法
  - ❖ 线性判别分析
    - 最大化广义瑞利商
- 多分类学习
  - ❖ 一对一
  - ❖ 一对其余
- 类别不平衡问题
  - ❖ 基本策略：再缩放