

# 机器学习

Machine Learning

授课老师：谭毅华

电 话：13886021197

办 公 室：科技楼1102

邮 箱：[yhtan@hust.edu.cn](mailto:yhtan@hust.edu.cn)

# 第十一章、半监督学习

## 01 半监督学习问题

## 02 方法概述

生成式方法

Self-Training

半监督SVM

图半监督学习

基于分歧的方法

半监督聚类

## 03 领域前沿

## 目录 CONTENTS

为人师表

# 1.半监督学习问题

□ **问题的提出：**在有标签样本较少时，如何利用无标签样本提升学习性能

**有监督的学习：**学习器通过对大量有标记的训练例进行学习，从而建立模型用于预测未见示例的标记(label)。**很难获得大量的标记样本。**

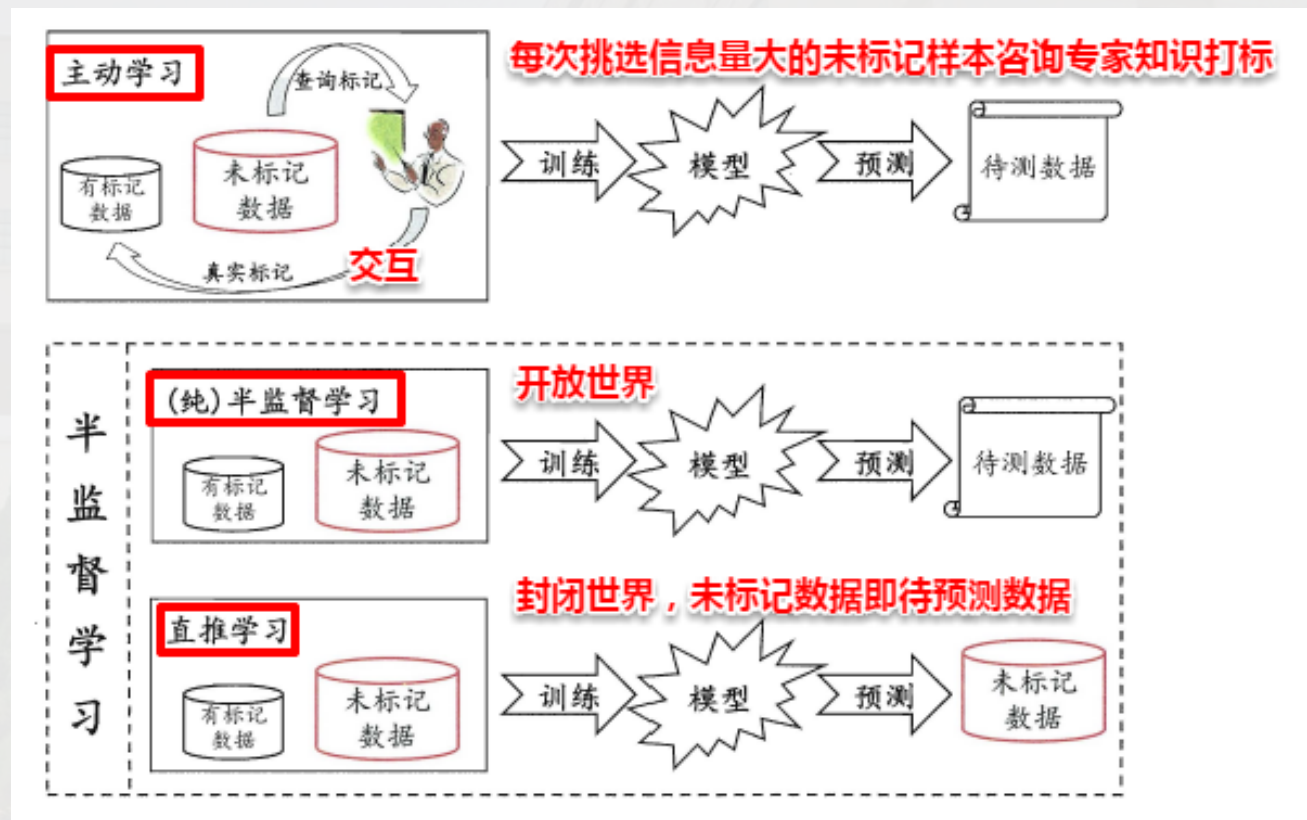
**无监督的学习：**无训练样本，仅根据测试样本的在特征空间分布情况进行标记，**准确性差。**

**半监督的学习：**有少量训练样本，学习机以从训练样本获得的知识为基础，结合测试样本的分布情况逐步修正已有知识，并判断测试样本的类别。

□ **主动学习：**需要与外界进行交互/查询/打标，其本质上仍然属于一种监督学习

## ● 半监督学习分为两类

- **纯半监督学习：**假定训练数据集中的未标记数据并非待预测数据
- **直推式学习：**学习过程中的未标记数据就是待预测数据






# 1. 半监督学习问题



训练集含有标记样本  $D_l = \{(x_1^l, y_1^l), (x_2^l, y_2^l), \dots, (x_n^l, y_n^l)\}$  和未标记样本  $D_u = \{x_1^u, x_2^u, \dots, x_m^u\}$



标注数据少，无法判断！


加入无标签数据后，能够判断！

## □ 半监督学习算法的成立依赖于以下假设：

- **聚类假设：**同一聚类中的样本点很可能具有同样的类别标记。关注样本空间的整体特征，探测样本分布稠密和稀疏的区域，从而更好地约束决策边界穿过稀疏区域
- **流形假设：**高维中的数据存在着低维的特性。利用大量的无标签样增加样本空间的密度，从而更准确地获取样本的局部近邻关系，是聚类假设的推广
- **平滑假设：**相似的样本具有相同的标签。

## 2.1.生成式方法

□ **有监督GMM**: 假定样本的概率由多个高斯分布组合形成, 从而一个子高斯分布就代表一个类别。(假设各子高斯分布协方差相同)



有标签数据的对数似然:

$$\log L(\theta) = \sum_{x^r} \log P_{\theta}(x^r, \hat{y}^r)$$

$$P_{\theta}(x^r, \hat{y}^r) = P_{\theta}(x^r | \hat{y}^r) P(\hat{y}^r)$$

使用EM算法最大化对数似然

$$p(x|C_i) = N(x|\mu_u, \Sigma)$$


$$p(C_i|x) = \frac{p(x|C_i)p(C_i)}{\sum_{i=1}^N p(x|C_i)p(C_i)}$$

$$C(x) = \operatorname{argmax} p(C_i|x)$$



## 2.1.生成式方法

□ 半监督GMM：无标签数据使我们需要重新估计高斯分布的参数



有标签数据与无标签数据的对数似然：

$$\log L(\theta) = \sum_{x^r} \log P_{\theta}(x^r, \hat{y}^r) + \sum_{x^u} \log P_{\theta}(x^u)$$

$$P_{\theta}(x^r, \hat{y}^r) = P_{\theta}(x^r | \hat{y}^r) P(\hat{y}^r)$$

$$P_{\theta}(x^u) = P_{\theta}(x^u | C_1) P(C_1) + P_{\theta}(x^u | C_2) P(C_2)$$

使用EM算法最大化对数似然

## 2.1.生成式方法

### □ 半监督GMM: 参数估计迭代计算步骤

- 初始化参数:  $\theta = \{P(C_1), P(C_2), \mu^1, \mu^2, \Sigma\}$

- E** • 计算无标签数据的后验概率:  $P_{\theta}(C_1|x^u)$

- M** • 更新模型参数:

$$P(C_1) = \frac{N_1 + \sum_{x^u} P(C_1|x^u)}{N}$$

$N_1$ : 有标签数据中属于 $C_1$ 的样本数量  
 $N$ : 总样本数量  
 $\sum_{x^u} P(C_1|x^u)$ : 无标签样本属于 $C_1$ 的概率之和

$$\mu^1 = \frac{1}{N_1} \sum_{x^r \in C_1} x^r + \frac{1}{\sum_{x^u} P(C_1|x^u)} \sum_{x^u} P(C_1|x^u) x^u \dots\dots \text{(更新 } \mu_i, \Sigma_i, P(C_i) \text{)}$$



## 2.2.Self-Training

□ 给定有标签集 $\{(x^l, y^l)\}$ , 无标签集 $\{x^u\}$

□ Repeat:

- 在有标签集上训练模型 $f^*$  (方法与模型无关)
- 在无标签集上应用模型, 计算无标签样本的伪标签 $y^u$
- 从无标签集中移除一部分样本, 将其加入有标签集

□ 如何选择将哪些样本加入有标签集, 哪些样本仍留在无标签集?

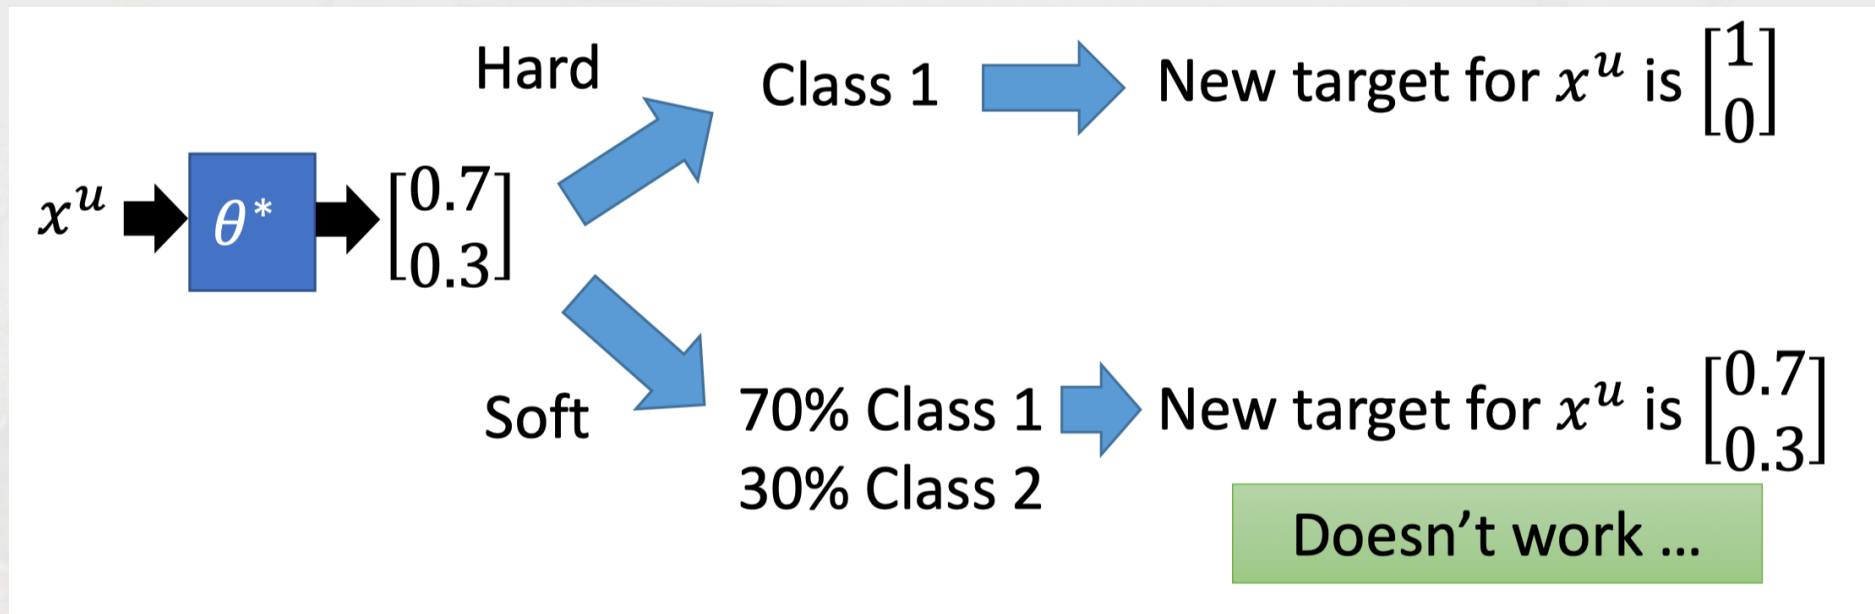
——为每个样本提供一个权重

□ Self-Training 无法用于回归任务




## 2.2.Self-Training

- 思想类似于生成式方法
- 思考：伪标签 Soft Label v.s. Hard Label
- 考虑神经网络模型，网络参数 $\theta^*$



## 2.2. Self-Training——熵正则化

□ 限制 $y^u$ 的分布，使其更集中



$$E(y^u) = 0$$

$$E(y^u) = 0$$

$$E(y^u) = \log 5$$

$$E(y^u) = - \sum_{c=1}^5 y_c^u \log y_c^u$$

期望E越小越好

$$Loss = \sum_{x^l} CE(y^l, \hat{y}^l) + \lambda \sum_{x^u} E(y^u)$$

有标签数据


无标签数据

or 选择熵较小的无标签数据加入有标签集进行Self-Training



## 2.3.半监督SVM

- **TSVM(Transductive SVM)**: 尝试为未标记样本找到合适的标记指派, 使得超平面划分后的间隔最大化 (低密度分割假设)



## 2.3. 半监督SVM



$$D = \{(x_1, y_1), \dots, (x_l, y_l), x_{l+1}, \dots, x_m\} \quad \{D_l, D_u\}$$

□ TSVM目标: 为 $D_u$ 中的样本给出预测标记 $\hat{y} = (\hat{y}_{l+1}, \hat{y}_{l+2}, \dots, \hat{y}_m)$ ,  $\hat{y}_i \in \{-1, +1\}$ , 满足:

$$\begin{aligned} \min_{w, b, \hat{y}, \xi} \quad & \frac{1}{2} \|w\|_2^2 + C_l \sum_{i=1}^l \xi_i + C_u \sum_{i=l+1}^m \xi_i \rightarrow \text{松弛变量 hinge 损失} \\ \text{s.t.} \quad & y_i(w^T x_i + b) \geq 1 - \xi_i, \quad i = 1, 2, \dots, l, \\ & \hat{y}_i(w^T x_i + b) \geq 1 - \xi_i, \quad i = l+1, l+2, \dots, m, \\ & \xi_i \geq 0, \quad i = 1, 2, \dots, m, \end{aligned}$$

对应标记样本

对应未标记样本

$C_l$ 与 $C_u$ 用于平衡模型复杂度、有标记样本与未标记样本重要程度的折中参数

穷举每个无标签样本的预测标记计算复杂度过高, TSVM采用迭代策略




## 2.3. 半监督SVM

□ TSVM求解：迭代地进行局部搜索。分两个环节：分配伪标记并获得初始SVM、交换错分的未标记样本更新SVM

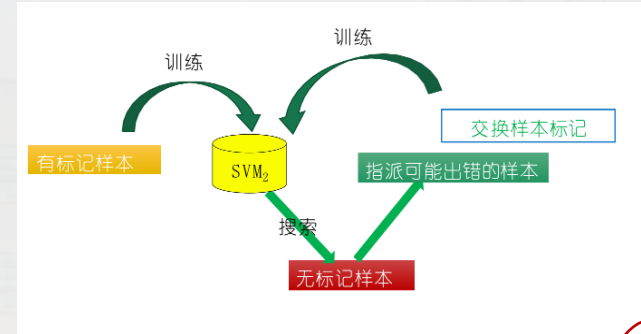
### 1. 计算初始SVM

- 有标记样本训练SVM
- 获得未标记样本的伪标签后，再训练SVM



### 2. 交换标记重复训练SVM

- 挑选两个可能错分的异类未标记样本
- 交换其标签，重新训练SVM



挑选准则

- 减轻类别不平衡的影响，基于伪标记而当作正反例的未标记样本数，将 $C_u$ 拆为 $C_u^+$ 、 $C_u^-$

$$C_u^+ = \frac{u_-}{u_+} C_u^-$$

输入：有标记样本集  $D_l = \{(x_1, y_1), (x_2, y_2), \dots, (x_l, y_l)\}$ ;  
未标记样本集  $D_u = \{x_{l+1}, x_{l+2}, \dots, x_{l+u}\}$ ;  
折中参数  $C_l, C_u$ .


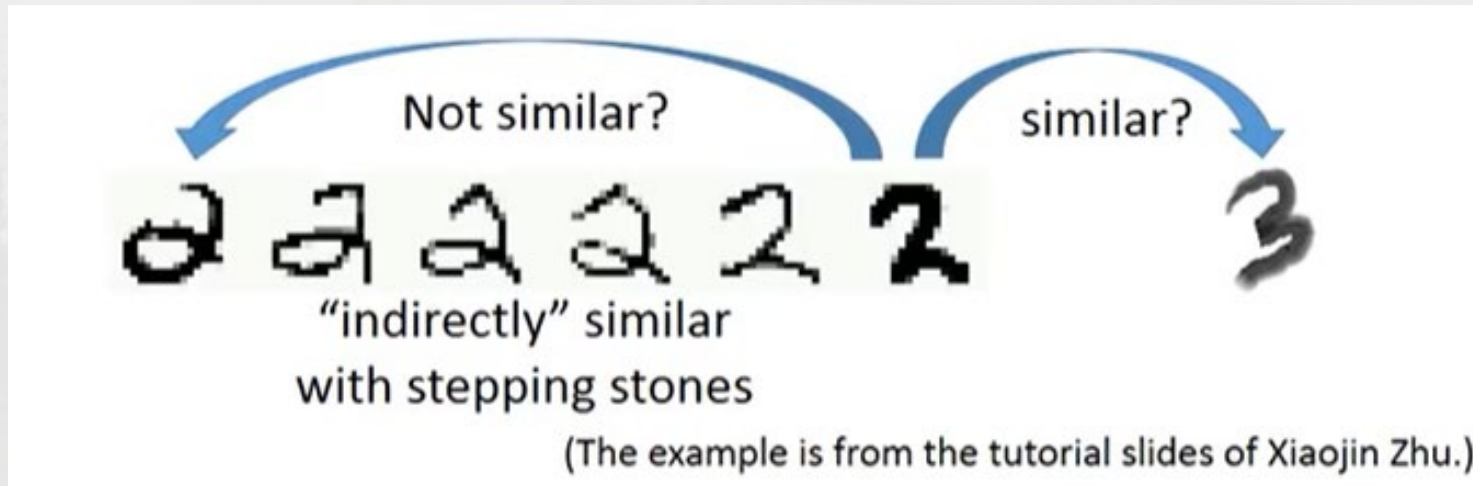
过程：

- 1: 用  $D_l$  训练一个  $SVM_l$ ; **初始SVM**
- 2: 用  $SVM_l$  对  $D_u$  中样本进行预测，得到  $\hat{y} = (\hat{y}_{l+1}, \hat{y}_{l+2}, \dots, \hat{y}_{l+u})$ ;
- 3: 初始化  $C_u \ll C_l$ ;
- 4: **while**  $C_u < C_l$  **do**
- 5: 基于  $D_l, D_u, \hat{y}, C_l, C_u$  求解式(13.9)，得到  $(w, b), \xi$ ;
- 6: **while**  $\exists \{i, j \mid (\hat{y}_i \hat{y}_j < 0) \wedge (\xi_i > 0) \wedge (\xi_j > 0) \wedge (\xi_i + \xi_j > 2)\}$  **do**
- 7:  $\hat{y}_i = -\hat{y}_i$ ; **松弛变量越大表示离超平面越近，越容易分错**
- 8:  $\hat{y}_j = -\hat{y}_j$ ;
- 9: 基于  $D_l, D_u, \hat{y}, C_l, C_u$  重新求解式(13.9)，得到  $(w, b), \xi$
- 10: **end while**
- 11:  $C_u = \min\{2C_u, C_l\}$  **逐渐增大 $C_u$**
- 12: **end while**

输出：未标记样本的预测结果:  $\hat{y} = (\hat{y}_{l+1}, \hat{y}_{l+2}, \dots, \hat{y}_{l+u})$  **最终调整后的结果**

## 2.4.图半监督学习——平滑假设

- 平滑假设：相似的样本具有相同的标签
- 样本 $x$ 的分布非均匀
- 若 $x^1$ 和 $x^2$ 在高密度区域相邻，则具有相同的标签



$x^1 x^2$  具有相同标签  
 $x^2 x^3$  具有不同标签

$x^1 x^2$  are connected  
by a high density path



## 2.4.图半监督学习



### □ 如何判断样本在高密度区域相邻?

——使用图结构描述样本点


### □ 如何构建图?

1. 具有自然的图结构: 网页链接、论文引用.....
2. 从数据构建图:

- 计算样本之间的相似度  $s(x^i, x^j) = \exp(-\gamma \|x^i - x^j\|^2)$
- 将K近邻相连
- 将一定范围内的样本相连






- 边的权重正比于  $s(x^i, x^j)$



## 2.4.图半监督学习

□ 节点标签扩散：将已标记样本根据样本特征的相似性进行扩散，获得未标记样本的标记。






## 2.4.图半监督学习



### □ 能量函数：定性评价图的平滑性

$$E = \frac{1}{2} \sum_{i,j} w_{i,j} (y^i - y^j)^2 = \mathbf{y}^T \mathbf{L} \mathbf{y}$$

对于所有样本进行计算（包括有标签数据和无标签数据），越小越好



$\mathbf{y}$ : 所有样本的标预测标签  $(R + U)$ 维

$$\mathbf{y} = [\dots y^i \dots y^j]^T \quad \mathbf{y} = (\mathbf{y}_l^T, \mathbf{y}_u^T)$$

$\mathbf{L}$ : 图拉普拉斯矩阵  $(R + U) \times (R + U)$ 维

$$\mathbf{L} = \mathbf{D} - \mathbf{W}$$

$$(\mathbf{W})_{ij} = \begin{cases} \exp\left(\frac{-\|\mathbf{x}_i - \mathbf{x}_j\|_2^2}{2\sigma^2}\right), & \text{if } i \neq j; \\ 0, & \text{otherwise,} \end{cases}$$

$$\mathbf{W} = \begin{bmatrix} 0 & 2 & 3 & 0 \\ 2 & 0 & 1 & 0 \\ 3 & 1 & 0 & 1 \\ 0 & 0 & 1 & 0 \end{bmatrix} \quad \mathbf{D} = \begin{bmatrix} 5 & 0 & 0 & 0 \\ 0 & 3 & 0 & 0 \\ 0 & 0 & 5 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}$$

## 2.4.图半监督学习



□ 求解：1. 作为正则项，使用梯度下降求解

$$E = \frac{1}{2} \sum_{i,j} w_{i,j} (y^i - y^j)^2 = \mathbf{y}^T L \mathbf{y} \quad \text{Loss} = \sum_{x^l} CE(y^l, \hat{y}^l) + \lambda E$$

□ 求解：2. 解析解

设 $\mathbf{y}$ 由判别函数 $f$ 求得，即 $y_i = \text{sign}(f(x_i))$ ， $f = (\mathbf{f}_l^T, \mathbf{f}_u^T)$ ，可令 $E = \mathbf{f}^T L \mathbf{f}$

写成分块矩阵形式：

$$E(f) = (\mathbf{f}_l^T \ \mathbf{f}_u^T) \left( \begin{bmatrix} \mathbf{D}_{ll} & \mathbf{0}_{lu} \\ \mathbf{0}_{ul} & \mathbf{D}_{uu} \end{bmatrix} - \begin{bmatrix} \mathbf{W}_{ll} & \mathbf{W}_{lu} \\ \mathbf{W}_{ul} & \mathbf{W}_{uu} \end{bmatrix} \right) \begin{bmatrix} \mathbf{f}_l \\ \mathbf{f}_u \end{bmatrix} \quad (L = D - W)$$

最小化能量函数：  $\frac{\partial E(f)}{\partial \mathbf{f}_u} = \mathbf{0}$  解得：  $\mathbf{f}_u = (\mathbf{D}_{uu} - \mathbf{W}_{uu})^{-1} \mathbf{W}_{ul} \mathbf{f}_l$  .

令  $\mathbf{P}_{uu} = \mathbf{D}_{uu}^{-1} \mathbf{W}_{uu}$ ,  $\mathbf{P}_{ul} = \mathbf{D}_{uu}^{-1} \mathbf{W}_{ul}$  则  $\mathbf{f}_u = (\mathbf{I} - \mathbf{P}_{uu})^{-1} \mathbf{P}_{ul} \mathbf{f}_l$

代入 $D$ 、 $W$ 、 $\mathbf{f}_l$ 即可求得 $\mathbf{f}_u$



## 2.5.基于分歧的方法

□ 多视图数据：一个数据对象有多个属性集，每个属性集构成了视图。

- 样本  $(\langle x^1, x^2 \rangle, y)$ ，其中  $x^i$  为样本在视图  $i$  中的示例， $y$  为标记
- 例如电影中的声音和视频分别对应一个视图，类型则为“动作片”、“爱情片”等

□ 多视图具有相容性，进而具有互补性

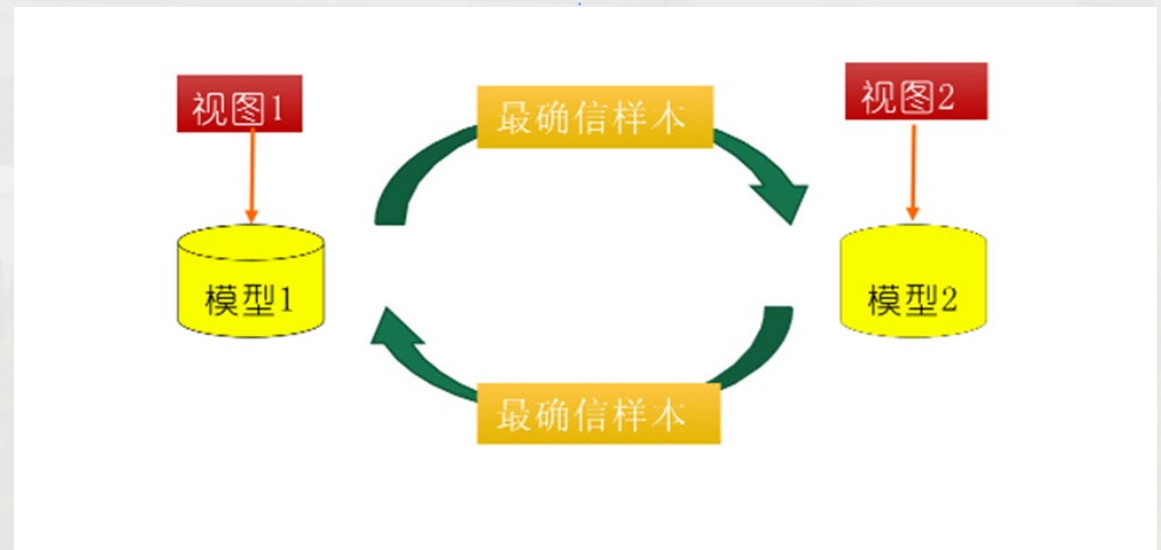
- 不同视图输出空间是一致的，以电影为例，类别均应为{爱情片、动作片}
- 故可利用多视图的互补性加强分类的准确性

## 2.5.基于分歧的方法

□ 协同训练：基于两个充分且条件独立的视图，利用未标记数据相互促进。

- 充分：每个视图均包含产生最优学习器的信息
- 条件独立：给定类别标记条件下，两个视图独立

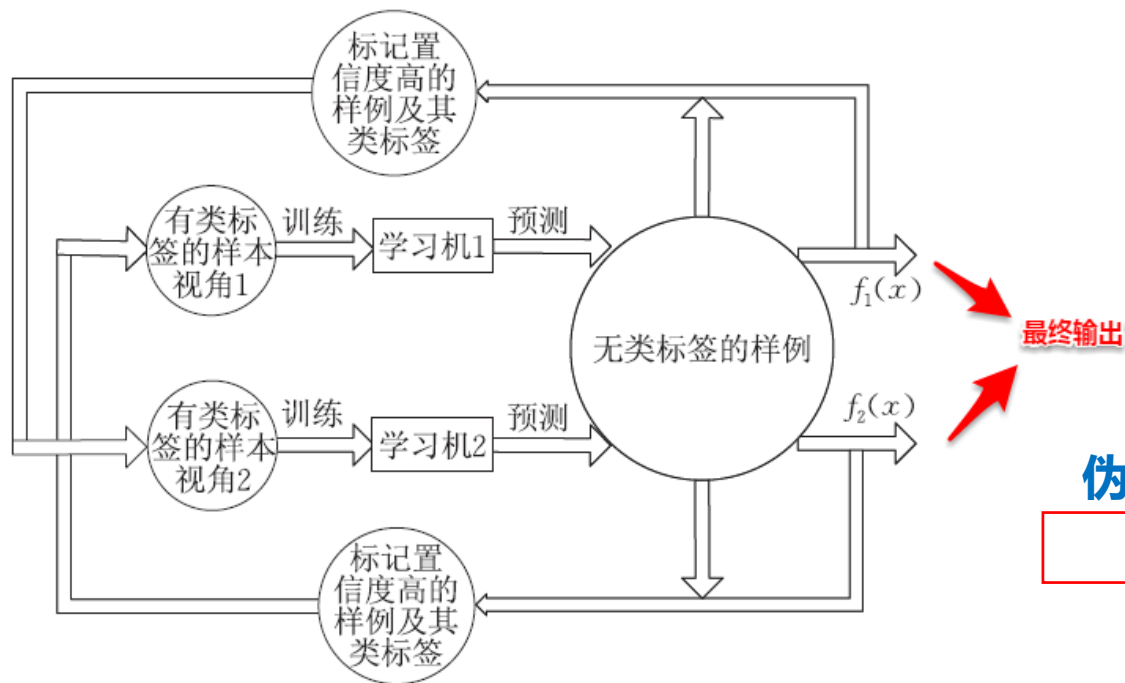
- 基于标记样本训练视图模型1
- 以模型1挑选出该视图最确信的未标记样本赋予其伪标记，并将以上伪标记样本作为新的标记样本加至视图模型2的训练集
- 对视图2模型进行训练，进而挑出该视图模型最确信的未标记样本赋予其伪标记，将其加至视图模型1的训练集
- 重复以上两步，直到两个分类器不变





## 2.5.基于分歧的方法

### 协同训练算法



研究表明，协同训练无需多多视图数据，只要保证多个弱学习器之间有显著分歧即可

输入：有标记样本集  $D_l = \{(\langle x_1^1, x_1^2 \rangle, y_1), \dots, (\langle x_l^1, x_l^2 \rangle, y_l)\}$ ;  
未标记样本集  $D_u = \{\langle x_{l+1}^1, x_{l+1}^2 \rangle, \dots, \langle x_{l+u}^1, x_{l+u}^2 \rangle\}$ ;  
缓冲池大小  $s$ ;  
每轮挑选的正例数  $p$ ;  
每轮挑选的反例数  $n$ ;  
基学习算法  $\mathcal{L}$ ;  
学习轮数  $T$ .

过程：

- 1: 从  $D_u$  中随机抽取  $s$  个样本构成缓冲池  $D_s$ ;
- 2:  $D_u = D_u \setminus D_s$ ;
- 3: for  $j = 1, 2$  do
- 4:  $D_l^j = \{(\langle x_i^j, y_i \rangle) \mid (\langle x_i^j, x_i^{3-j} \rangle, y_i) \in D_l\}$ ; 各视图的有标记样本
- 5: end for
- 6: for  $t = 1, 2, \dots, T$  do
- 7: for  $j = 1, 2$  do
- 8:  $h_j \leftarrow \mathcal{L}(D_l^j)$ ; 基于每个视图训练初始学习器
- 9: 考察  $h_j$  在  $D_s^j = \{\langle x_i^j, x_i^{3-j} \rangle \mid \langle x_i^j, x_i^{3-j} \rangle \in D_s\}$  上的分类置信度 挑选  $p$  个正例置信度最高的样本  $D_p \subset D_s$ 、 $n$  个反例置信度最高的样本  $D_n \subset D_s$ ;
- 10: 由  $D_p^j$  生成伪标记正例  $\tilde{D}_p^{3-j} = \{(\langle x_i^{3-j}, +1 \rangle \mid x_i^j \in D_p^j)\}$ ;
- 11: 由  $D_n^j$  生成伪标记反例  $\tilde{D}_n^{3-j} = \{(\langle x_i^{3-j}, -1 \rangle \mid x_i^j \in D_n^j)\}$ ;
- 12:  $D_s = D_s \setminus (D_p \cup D_n)$ ; 两个学习器挑选的不会有重复
- 13: end for
- 14: if  $h_1, h_2$  均未发生改变 then
- 15: break
- 16: else
- 17: for  $j = 1, 2$  do
- 18:  $D_l^j = D_l^j \cup (\tilde{D}_p^{3-j} \cup \tilde{D}_n^{3-j})$ ; 加入打过伪标的未标记样本
- 19: end for
- 20: 从  $D_u$  中随机抽取  $2p + 2n$  个样本加入  $D_s$  补充缓冲池
- 21: end if
- 22: end for

输出：分类器  $h_1, h_2$  最终输出两个分类器做集成


## 2.6.半监督聚类

□ 拥有部分额外监督信息时：可利用监督信息改善聚类效果。

□ 两种监督信息：

- 约束：必连（实线）与勿连（虚线）

- 少量有标签样本





## 2.6.半监督聚类



### □ 约束K-均值算法

输入: 样本集  $D = \{x_1, x_2, \dots, x_m\}$ ;  
必连约束集合  $\mathcal{M}$ ;  
勿连约束集合  $\mathcal{C}$ ;  
聚类簇数  $k$ .


过程:

```
1: 从  $D$  中随机选取  $k$  个样本作为初始均值向量  $\{\mu_1, \mu_2, \dots, \mu_k\}$ ;  
2: repeat  
3:    $C_j = \emptyset$  ( $1 \leq j \leq k$ );  
4:   for  $i = 1, 2, \dots, m$  do  
5:     计算样本  $x_i$  与各均值向量  $\mu_j$  ( $1 \leq j \leq k$ ) 的距离:  $d_{ij} = \|x_i - \mu_j\|_2$ ;  
6:      $\mathcal{K} = \{1, 2, \dots, k\}$ ;  
7:     is_merged=false;  
8:     while  $\neg$  is_merged do  
9:       基于  $\mathcal{K}$  找出与样本  $x_i$  距离最近的簇:  $r = \arg \min_{j \in \mathcal{K}} d_{ij}$ ;  
10:      检测将  $x_i$  划入聚类簇  $C_r$  是否会违背  $\mathcal{M}$  与  $\mathcal{C}$  中的约束;  
11:      if  $\neg$  is_violated then  
12:         $C_r = C_r \cup \{x_i\}$ ;  
13:        is_merged=true  
14:      else  
15:         $\mathcal{K} = \mathcal{K} \setminus \{r\}$ ; 若不满足则寻找距离次小的类簇  
16:        if  $\mathcal{K} = \emptyset$  then  
17:          break并返回错误提示  
18:        end if  
19:      end if  
20:    end while  
21:  end for  
22:  for  $j = 1, 2, \dots, k$  do  
23:     $\mu_j = \frac{1}{|C_j|} \sum_{x \in C_j} x$ ;  
24:  end for  
25: until 均值向量均未更新  
输出: 簇划分  $\{C_1, C_2, \dots, C_k\}$ 
```


对样本进行划分时, 需检测是否满足约束关系, 其它步骤均相同

在标准K-Means算法中加入对约束的检测, 依次判断距离无标签样本最近的簇是否满足约束


### ● 西瓜数据集4.0,施加若干必连和勿连约束, 聚类迭代过程




(a) 第1轮迭代后



(c) 第3轮迭代后



(b) 第2轮迭代后



(d) 第4轮迭代后

## 2.6.半监督聚类



### □ 少量有标记样本的聚类算法

输入: 样本集  $D = \{x_1, x_2, \dots, x_m\}$ ;  
少量有标记样本  $S = \bigcup_{j=1}^k S_j$ ;  
聚类簇数  $k$ .

过程:

```
1: for  $j = 1, 2, \dots, k$  do
2:    $\mu_j = \frac{1}{|S_j|} \sum_{x \in S_j} x$ 
3: end for
4: repeat
5:    $C_j = \emptyset$  ( $1 \leq j \leq k$ );
6:   for  $j = 1, 2, \dots, k$  do
7:     for all  $x \in S_j$  do
8:        $C_j = C_j \cup \{x\}$ 
9:     end for
10:  end for
11:  for all  $x_i \in D \setminus S$  do
12:    计算样本  $x_i$  与各均值向量  $\mu_j$  ( $1 \leq j \leq k$ ) 的距离:  $d_{ij} = \|x_i - \mu_j\|_2$ ;
13:    找出与样本  $x_i$  距离最近的簇:  $r = \arg \min_{j \in \{1, 2, \dots, k\}} d_{ij}$ ;
14:    将样本  $x_i$  划入相应的簇:  $C_r = C_r \cup \{x_i\}$ 
15:  end for
16:  for  $j = 1, 2, \dots, k$  do
17:     $\mu_j = \frac{1}{|C_j|} \sum_{x \in C_j} x$ ;
18:  end for
19: until 均值向量均未更新
输出: 簇划分  $\{C_1, C_2, \dots, C_k\}$ 
```

使用带标记样本各类别的均值向量作为初始类中心


带标记样本直接划入对应类簇

划分无标记样本


重新计算类中心

先根据有标记样本初始化聚类中心, 再使用K-Means算法划分无标记样本


### ● 西瓜数据集4.0, 假定部分样本类别已知




(a) 第1轮迭代后



(b) 第2轮迭代后



(c) 第2轮迭代后



(d) 第4轮迭代后

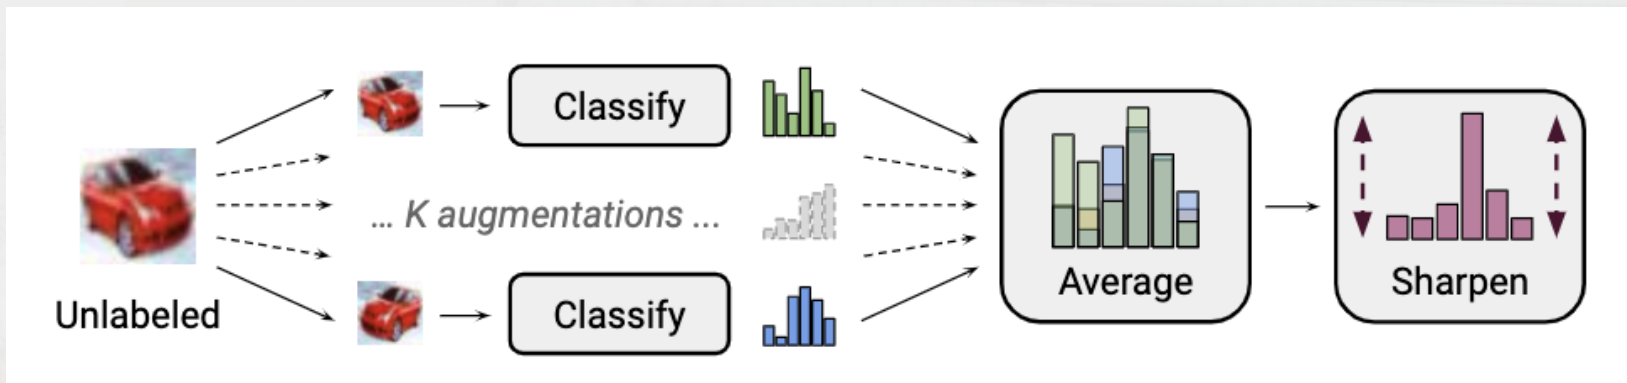
@yan

### 3. 领域前沿



#### □ XX-Match

- **一致性正则：** 给输入加入扰动，模型的输出应该尽可能保持不变或者近似
  - 注入 noise 可以通过模型本身的随机性（如 dropout）或者直接加入噪声，也可以通过 data augmentation；计算一致性的方法，可以使用 L2，也可以使用 KL divergency、cross entropy。
- **熵最小化：** 要求预测近似于one-hot标签



#### MixMatch:

多次数据增强后取平均预测  
作为伪标签

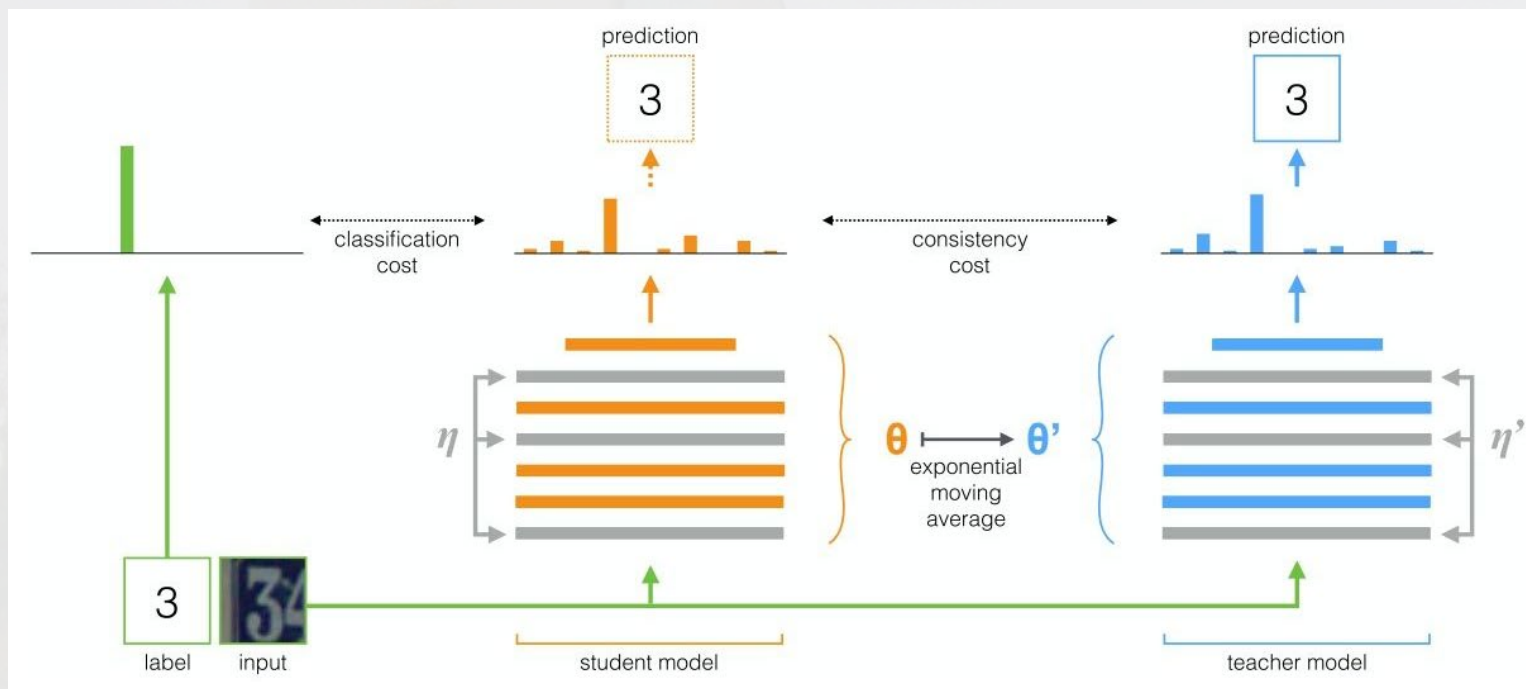
- **MixMatch:** A Holistic Approach to Semi-Supervised Learning
- **ReMixMatch:** Semi-Supervised Learning with Distribution Alignment and Augmentation Anchoring
- **UDA:** Unsupervised Data Augmentation for Consistency Training
- **FixMatch:** Simplifying Semi-Supervised Learning with Consistency and Confidence



### 3. 领域前沿

#### Teacher Student Model

- 包含两个model, 一个student, 一个teacher, teacher引导student从数据中学习 “知识”



#### Mean Teachers:

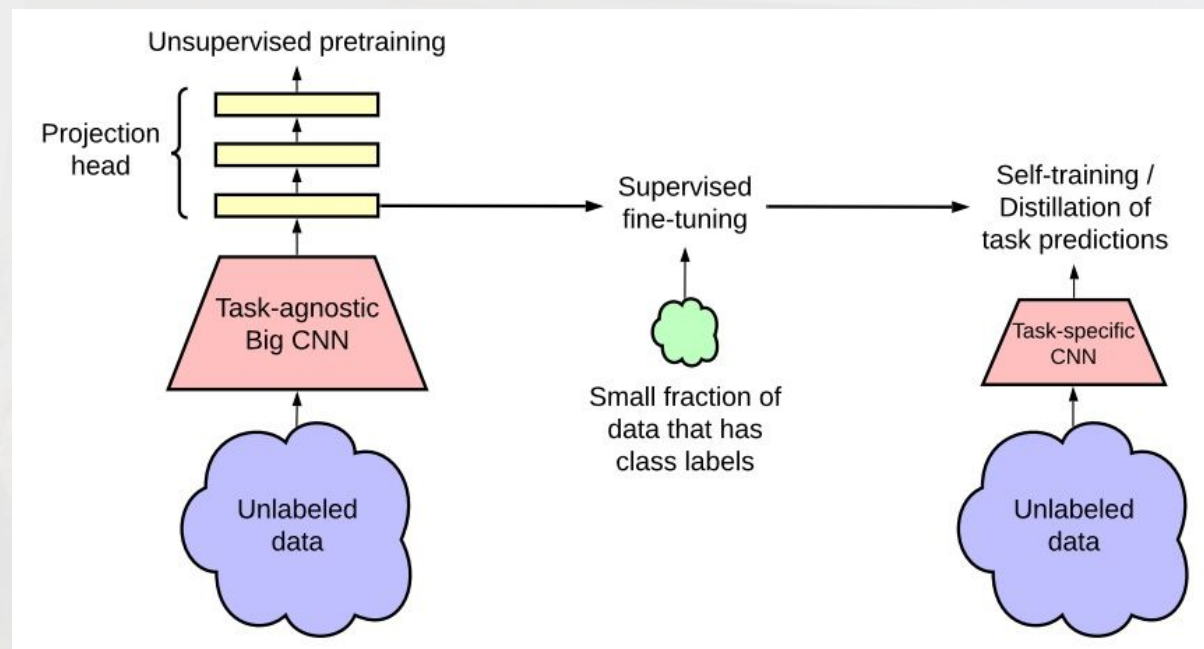
对Student的预测计算分类损失  
Student和Teacher之间计算一致性损失  
Teacher使用指数滑动平均进行更新

- Temporal Ensembling for Semi-Supervised Learning
- Mean teachers are better role models: Weight-averaged consistency targets improve semi-supervised deep learning results

### 3. 领域前沿

#### □ Self-supervised based SSL

- 使用自监督方法进行预训练，再使用有标签数据进行微调



#### Big Self-Supervised Models:

先试用自监督学习进行预训练


再使用有监督学习进行微调

最后在半监督数据集上进行Self-Training

- S4L: Self-Supervised Semi-Supervised Learning
- Big Self-Supervised Models are Strong Semi-Supervised Learners




## 4. 相关文献



Introduction to Semi-Supervised Learning

Xiaojin Zhu and  
Andrew B. Goldberg



Semi-Supervised Learning

Chapelle Olivier;  
Scholkopf Bernhard;  
Zien Alexander

视频教学:

[https://www.youtube.com/watch?v=fX\\_guE7JNnY&list=PLJV\\_el3uVTsPy9oCRY30oBPNLCo89yu49&index=14](https://www.youtube.com/watch?v=fX_guE7JNnY&list=PLJV_el3uVTsPy9oCRY30oBPNLCo89yu49&index=14)

相关资料汇总: <https://github.com/yassouali/awesome-semi-supervised-learning>



## • 本章小结

- 建立无标记样本利用的概念
- 高斯混合模型实现赋予未标记样本伪标签
- Self-Training: 自我迭代确定伪标签
- TSVM法利用局部搜索异类错分未标记样本迭代求近似解
- 图半监督学习: 二分类的扩散方法和多类情况的迭代传播算法
- 基于分歧的方法: 多视图协同训练
- 半监督聚类: 先验约束和部分标记样本